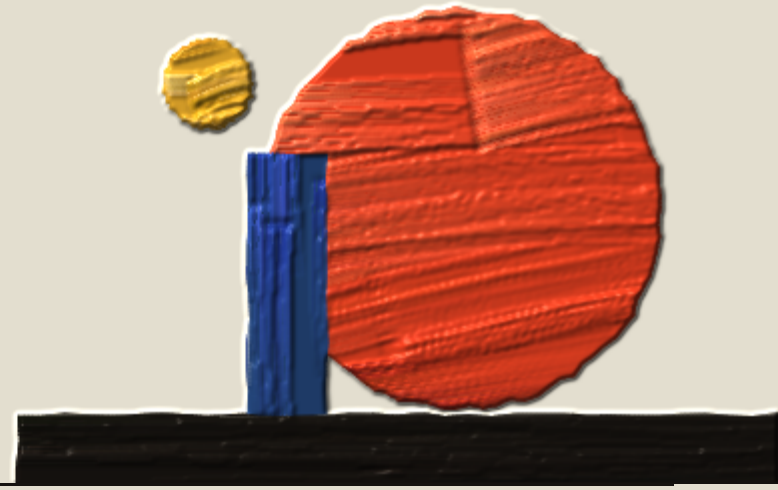
JOSE MANUEL ROJAS

JOSE MANUEL ROJAS



No adivino. Verifico.

Sistemas de IA que se pueden verificar.

WhatsApp josem.r2026@gmail.com aishiftdigital.com
LinkedIn GitHub

PERFIL

Estudiante de séptimo semestre de Ingeniería de Sistemas en la Universidad Icesi. Construyo agentes, RAG y modelos predictivos, y los rodeo de pruebas, guardias y revisión humana para que no adivinen. Uso la IA como equipo de desarrollo: yo defino la arquitectura, los contratos y los criterios de aceptación, y los agentes trabajan dentro de su carril.

Busco práctica profesional y proyectos de IA aplicada.

MÉTODO

CÓMO TRABAJO CON IA

- **Primero el contrato, después el código.** Requerimiento y criterios de aceptación se escriben antes de la primera línea.
- **Lo peligroso se bloquea.** Push a main, force-push, borrados masivos y leer .env se bloquean, no se piden con cortesía.
- **Dos fallos y entra una persona.** Tras dos fallos el agente investiga; al tercero pasa a un humano. Nada se sube sin mi OK.
- **Cada agente en su carril.** Un guardia bloquea ediciones fuera de las rutas del agente, también en ramas paralelas.
- **Probado o no está hecho.** Pruebas, tipos, lint y secretos antes de dar algo por terminado. Luego revisión en paralelo.
- **Memoria por capas.** Corto plazo: eventos de sesión. Mediano: estado fijado en el issue. Largo: ADR y lecciones.

PROYECTOS

AgentSprint: tablero de sprints que le da memoria a los agentes de código

42

HERRAMIENTAS MCP

PUBLICADO EN NPM, V0.2.1

Código abierto, licencia MIT

Un tablero de sprints que vive en Git y le da memoria a los agentes de código: cada sesión empieza con un resumen de dónde quedó el proyecto y termina con un traspaso para la siguiente.

- Servidor MCP con 42 herramientas y 7 prompts: cada sesión de Claude Code recibe el resumen del proyecto (sprint activo, qué espera revisión, qué sigue, bloqueos y lecciones) y cierra con un traspaso en un diario.
- Filtro de revisión: revisores de solo lectura juzgan cada tarea y la devuelven con hallazgos si no está bien, así solo miras lo que ya pasó. También se puede aprobar desde el chat.
- Monorepo de 5 paquetes en TypeScript (núcleo, CLI, MCP, servidor y web en React) con 46 archivos de prueba, integración continua y documentación publicada.

TypeScript, Node.js, MCP, React, Fastify, Zod, Vitest, GitHub Actions

RAG multimodal: recuperación y fusión entre modalidades

0,89

RECALL@1 TEXTO A IMAGEN

INVESTIGACIÓN

Curso de Inteligencia Artificial, 2026

Estudio experimental de cómo recuperar y combinar evidencia de texto, imagen, audio y tablas en un sistema RAG, con resultados y límites reportados sin maquillaje.

- Texto a imagen con CLIP ViT-B/32 sobre Flickr30k: Recall@1 de 0,89 y MRR de 0,936 en 100 consultas.
- Texto a audio con CLAP sobre AudioCaps: Recall@10 de 0,98.
- Tablas: al añadir estructura (empresa, región, frecuencia) el Recall@1 subió de 0,67 a 1,00 frente a TF-IDF en un corpus controlado.

Los benchmarks son pequeños y en parte sintéticos, y el trabajo lo declara.

Python, sentence-transformers, CLAP, scikit-learn, Colab

Memoria de tres niveles y servidores MCP para agentes

3

NIVELES DE MEMORIA

RETO DE CLASE

Curso de Inteligencia Artificial, 2026

Un gestor que le da memoria a un asistente en tres niveles, un RAG sobre PDF evaluado con RAGAS y dos servidores MCP para conectar herramientas a un agente.

- Tres niveles de memoria coordinados por un gestor: corto (los últimos 10 mensajes), medio (resumen de la sesión con vigencia de 14 días) y largo (hechos duraderos con importancia, recencia y «derecho al olvido»).
- Dos servidores MCP en Python (FastMCP): uno de notas con 3 herramientas y otro que busca y lee la documentación oficial de LangChain a partir de su índice llms.txt.

La evaluación es pequeña: 5 preguntas sobre un solo documento.

Python, Claude, ChromaDB, MCP (FastMCP), RAGAS, sentence-transformers, LangSmith



4 a 20x

MÁS BARATO EL AGENTE ÚNICO

INVESTIGACIÓN

Experimento del curso de IA, 2026

Arquitectura multiagente medida: ¿vale la pena un equipo de agentes?

Un sistema de agentes (orquestador, investigadores en paralelo, redactor y crítico) comparado contra un agente único con modelos reales, midiendo calidad, costo, latencia y costo de coordinación.

- El agente único resultó entre 4 y 20 veces más barato y entre 2,5 y 6 veces más rápido, con calidad igual o mejor. Coordinar consume entre 21 % y 40 % del costo.
- Medí el ruido: el orden entre agente único y multiagente se invierte entre las dos implementaciones, así que solo declaro firmes las diferencias de costo, latencia y número de llamadas.

Parte de los notebooks base del curso, ejecutados con modelos reales, corregidos y documentados.

Python, LangGraph, OpenRouter, DeepSeek, Claude (juez), Pydantic, Jupyter



12

MODELOS COMPARADOS

EN DESARROLLO

Reto de IA con una empresa del sector salud

Winback: predicción de reactivación y chatbot de WhatsApp

Modelo que estima la probabilidad de que un afiliado retirado se reactive en 12 meses, para decidir a quién contactar primero, más un chatbot que conversa y pasa a un asesor a quien quiere volver.

- 12 modelos comparados con intervalos de confianza por bootstrap. Elegí XGBoost por simplicidad, porque los ensambles empataban dentro del error.
- Etiquetas barajadas para descartar fuga, calibración de probabilidades y una auditoría interna con 10 fallas corregidas.
- Chatbot con reglas para baja, queja y asesor (sin gastar LLM); el modelo nunca ve la probabilidad ni datos de salud. Envío simulado, sin pruebas con WhatsApp real.

Python, XGBoost, scikit-learn, FastAPI, Next.js, Supabase, pgvector



233.280

PERFILES VERIFICADOS

PROTOTIPO DESPLEGADO

App móvil de entrenamiento (PWA)

Rytm: coach híbrido de pesas y carrera

PWA instalable en iPhone que guía la sesión de pesas serie a serie, cronometra el cardio, genera un plan a medida y suma un coach con IA y una red social.

- Coach con LLM multi-proveedor (Llama 3.3 en Workers AI por defecto; Gemini, Groq o Claude opcionales) que responde en bloques JSON validados por código.
- Motor de planes determinista, sin IA: 39 esqueletos de pesas, 12 plantillas de cardio y 700 ejercicios, con invariantes verificadas sobre 233.280 combinaciones de perfil.

Aún sin usuarios.

TypeScript, React 19, Vite, Cloudflare Workers, D1, Durable Objects, Workers AI



15

AGENTES CON CARRIL PROPIO

PRÓXIMAMENTE

Con Daniel Escobar

Shift OS y Panel: equipos de agentes de IA con aprobación humana

Sistema para organizar equipos de trabajo que usan IA: 15 agentes con carril propio, reglas versionadas y un panel donde se ve en tiempo real qué hace cada uno y se aprueba desde la web o por WhatsApp.

- Plugin versionado de Claude Code con 15 agentes, 8 skills, hooks y una constitución de trabajo.
- Mi parte: co-desarrollo, revisión de PRs y la idea de llevarlo a equipos de trabajo como producto, que es el siguiente paso.

Claude Code, Python, Astro, React, Supabase, Cloudflare Workers, n8n

EXPERIENCIA

Shift Digital 2026 - ACTUALIDAD

Cofundador. Agencia en etapa de lanzamiento: webs y automatización con IA para pymes en Colombia, Estados Unidos y España.

- Diseño y desarrollo de aishiftdigital.com, en producción, con captación de leads, bandeja privada y bot de Instagram.
- Productos propios: CRM de WhatsApp, agente de atención con Claude, Mostrador y Shift OS.

EDUCACIÓN

Universidad Icesi EN CURSO, SÉPTIMO SEMESTRE

Ingeniería de Sistemas. Inteligencia Artificial (retos con mentoría de la industria) y Computación en Internet III.

STACK

IA Y DATOS
Claude (Haiku, Sonnet, Opus), APIs compatibles con OpenAI (Groq), Workers AI y Gemini, RAG híbrido (texto completo y pgvector), ChromaDB y RAGAS, CLIP y CLAP, scikit-learn, XGBoost, LightGBM, Prompts con salida estructurada

AGENTES
Claude Code (hooks, skills, subagentes), LangGraph, MCP (servidores en Python), n8n, OpenCode, AgentSprint (npm)

LENGUAJES
TypeScript, Python, SQL, JavaScript

WEB Y BACKEND
React 19, Next.js, Astro, NestJS, FastAPI, Tailwind

DATOS E INFRAESTRUCTURA
PostgreSQL y Supabase (RLS), Cloudflare (Workers, D1, R2), Vercel y Netlify, Docker

CALIDAD
Vitest, Playwright, pgTAP, GitHub Actions

VIDEO Y AUDIO
GSAP, Remotion, ffmpeg, faster-whisper, Chatterbox

JOSE MANUEL ROJAS

JOSEM.R2026@GMAIL.COM AISHIFTDIGITAL.COM